

基于GARCH模型和机器学习的波动率预测与期权定价研究

蒋笑阳¹, 谢江宇¹, 颜廷正², 龚启辉¹

(1.浙江大学 管理学院,浙江 杭州 310058;2.浙江大学 经济学院,浙江 杭州 310058)

摘 要:作为期权定价的核心环节,波动率建模将直接关系到我国金融市场定价权的提升和风险防控体系的完善。聚焦沪深300股指期货期权定价中的波动率建模问题,基于GARCH模型族分析金融时间序列的波动聚集性和动态特征,构建GARCH(1,1)-t模型,捕捉沪深300指数收益率的时变波动率;并引入随机森林、XGBoost等机器学习算法,进一步挖掘多维度历史波动率滞后值、动量指标、成交量移动均值等特征,可提升复杂市场环境下的波动率预测精度。实证结果表明,GARCH模型对波动趋势具有较好的拟合能力,但在极端行情中存在响应滞后问题;机器学习模型凭借非线性建模优势,显著降低了短期波动率的预测误差。同时,研究发现,两类模型在期权定价中呈现互补性:机器学习模型在标的资产上行波动时表现突出;GARCH模型因对称假设对下行风险的稳健性,使其在认沽期权定价中表现更优。

关键词:GARCH模型;机器学习;沪深300股指期货期权;波动率预测;期权定价

中图分类号:F832.55

文献标识码:A

文章编号:1674-747X(2025)09-0077-16

引言

金融期权作为金融衍生品的重要工具,具有多方面的作用和意义。一方面,金融期权为投资者提供了多元化的风险管控和收益增强工具;另一方面,金融期权可以提升金融市场效率、对冲潜在风险。期权合约的隐含波动率、行权价分布等数据直接反映市场对标的资产未来波动的预期。因此,准确的期权定价模型至关重要。

期权的历史可追溯至古代。古希腊与古腓尼基的贸易活动中已出现类似期权的风险规避行为。17世纪荷兰“郁金香狂热”时期,期权即被用于交易,但因缺乏规范而失败。1973年,芝加哥期权交易所(CBOE)的成立,标志着现代期权市场的成立,其用标准化的合约和中央清算机制为规范交易奠定了良好的基础。同年,Black-Scholes模型的诞生为期权定价提供了科学方法,推动期权快速发展并扩展至

商品、指数、外汇等领域。此后,期权逐渐成为全球衍生品市场的核心工具。

我国的期权市场发展相对缓慢。2015年2月,上证50ETF期权作为首只场内期权上市,标志着中国开启了“期权时代”。此后,期权市场快速发展,从金融期权扩展至商品期权,品种覆盖股票、指数、农产品、工业品等。2019年12月14日,中国金融期货交易所发布沪深300股指期货期权合约及相关业务规则,标志着我国第一支股指期货期权——沪深300股指期货期权合约及规则准备工作正式完成。当前,我国资本市场正处于从“规模扩张”向“质量提升”的转型关键期。2023年,中央经济工作会议明确将“健全资本市场功能,提高直接融资比重”列为深化金融体制改革的核心任务,而《“十四五”资本市场发展规划》进一步提出要“构建规范、透明、开放、有活力、有韧性的市场生态”。在此背景下,期权定价研究的现实意义已超越微观模型优化,上升至服务国家金融改

收稿日期:2025-06-16

作者简介:蒋笑阳(2004—),男,浙江湖州人,主要研究方向为会计与资本市场;谢江宇(2004—),男,湖南郴州人,主要研究方向为概率论与数理金融;颜廷正(2004—),男,山东济宁人,主要研究方向为经济统计;龚启辉(1984—),男,湖南郴州人,副教授,会计学博士,主要研究方向为财务会计与资本市场。

革战略的宏观维度。

在金融市场量化分析和衍生品定价领域,波动率是十分重要的一个参数。作为 Black-Scholes (B-S) 欧式期权定价公式的核心输入参数,波动率的建模精度直接决定了期权定价是否准确有效,从而进一步影响市场风险管理的可靠性。Engle^[1]提出金融市场波动率具有时间序列的异方差性,并运用 ARCH 模型 (Autoregressive Conditional Heteroskedasticity, 自回归条件异方差模型) 来对波动率进行建模。Bollerslev^[2]在 ARCH 模型的基础上又提出了 GARCH 模型 (Generalized Autoregressive Conditional Heteroskedasticity, 广义自回归条件异方差模型)。GARCH 模型族对波动率预测的有效性已经得到了良好的检验。传统 GARCH 模型虽然可以较好地刻画金融时间序列的波动聚集性和时变性,但其依赖严格的时间序列分布假设,存在对复杂非线性波动模式的捕捉能力有限等问题,制约了 GARCH 模型对波动率预测精度的进一步提升。机器学习作为数据驱动的智能化工具,可以通过多层神经网络、集成学习等算法架构解决传统方案无法解决的问题,提供新环境下的新方案。我们将其用于 GARCH 模型的对比和优化,希望为波动率建模提供全新的技术路径。

2019 年沪深 300 股指期权的上市,标志着中国衍生品市场进入新的发展阶段,其隐含的波动率数据已成为衡量 A 股市场情绪的关键指标。与此同时,我国衍生品市场仍面临波动率建模精度不足、极端行情风险对冲效率有限等挑战。从资本市场高质量发展视角看,准确的期权定价至少具备三重战略价值:其一,为养老金、险资等长期资金提供精细化的风险对冲工具,助力解决我国资本市场“长钱短配”难题;其二,通过提升金融衍生品定价效率,增强中国 A 股市场对国际投资者的吸引力,推动资本市场的双向开放;其三,为我国科创板、北交所等创新板块的上市公司提供市值管理工具,服务国家创新驱动发展战略。正如 2024 年《国务院关于进一步提高上市公司质量的意见》所强调,“发展多元化风险管理工具是防范系统性风险、建设现代资本市场的基础工程”。波动率建模作为期权定价的核心环节,其研究进展直接关系到我国金融市场定价权的提升和风险防控体系的完善。

近年来,国内在波动率预测和期权定价领域的研究取得了一定进展,但多数研究仍停留在单一模型的应用或简单对比层面。例如,部分研究仅聚焦于 GARCH 模型族的扩展,试图通过改进模型参数或分布假设来提升波动率的捕捉能力,却忽视了机器学习方法在处理复杂非线性关系上的潜力^[3-4];另有研究虽引入机器学习算法,却未能充分发挥 GARCH 模型对金融时间序列波动聚集性等固有特征的理论刻画优势^[5]。本研究则突破这种单一化研究范式,将构建 GARCH(1,1)-t 模型精准捕捉沪深 300 指数收益率的时变波动率,并创新性地将随机森林、XGBoost 等机器学习算法与多维度特征工程相结合,所挖掘的历史波动率滞后值、动量指标、成交量移动均值等特征,比国内同类研究中常用的单一价格或收益率特征,能更全面地反映市场动态,从而在复杂市场环境下实现波动率预测精度的提升,为沪深 300 股指期权定价提供了更优的技术路径。本研究有望在理论上优化波动率建模模型,在实践中助力投资者制定科学的投资策略,并为中国股指期权市场的稳健运行与创新发展提供科学的量化工具。

一、研究综述

波动率作为刻画金融资产收益不确定性的核心指标,其建模理论和期权定价实践始终是金融研究的重要方向。早期 Black-Scholes 模型基于常数波动率假设构建了期权定价的理论框架^[6],但难以解释金融市场中普遍存在的波动聚类、时变性及杠杆效应等现象^[7]。20 世纪 80 年代,Engle^[1]提出的自回归条件异方差 (ARCH) 模型首次打破常数波动率假设,通过滞后残差平方项的线性组合刻画条件异方差,揭示了波动的动态依赖特征;Bollerslev^[2]进一步将其推广为广义的 ARCH (GARCH) 模型,通过引入条件方差的自回归项,有效捕捉了波动的长期记忆性,成为低频金融数据建模的经典框架。随着信息技术的发展,高频交易数据的可得性推动了波动率度量的革新:Andersen 等^[8]提出的“已实现波动率”通过日内收益率平方和直接估计真实波动率,显著提升了短期波动的预测精度;Corsi^[9]的 HAR-RV 模型 (Heterogeneous Autoregressive Model of Realized Volatility, 异质自回归已实现波动率模

型)整合日、周、月不同时间尺度的已实现波动率数据,反映了市场中短期、中期和长期投资者交易行为对波动的综合影响;Ghysels等^[10]的MIDAS模型(Mixed Data Sampling,混合数据抽样模型)则通过权重函数设计,实现了低频宏观经济数据与高频交易数据的融合,拓展了波动率模型对非同步数据的适应性。

针对金融市场波动的复杂特征(如不对称性、长记忆性),GARCH模型族通过技术改进形成了更精细的建模体系。Nelson^[11]提出的EGARCH模型(Exponential Generalized Autoregressive Conditional Heteroskedasticity,指数广义自回归条件异方差模型)通过对数变换放松方差非负约束,并引入不对称项刻画利空消息对波动的更强冲击,有效解决了传统模型对杠杆效应刻画不足的问题;Glosten等^[12]的TGARCH模型(Threshold Generalized Autoregressive Conditional Heteroskedasticity,门限广义自回归条件异方差模型)则通过虚拟变量区分正负残差影响,且当出现负向残差时激活额外波动项,更直观地捕捉了波动的不对称性。在长记忆性建模方面,Baillie等^[13]将分数阶差分引入GARCH框架,构建FIGARCH模型(Fractionally Integrated Generalized Autoregressive Conditional Heteroskedasticity,分数整合广义自回归条件异方差模型)以描述波动率的长期持续特征,突破了传统模型仅能刻画指数衰减记忆的限制;Tse^[14]的FIAPARCH模型(Fractionally Integrated Asymmetric Power ARCH,分数整合非对称幂ARCH模型)进一步结合幂变换,允许条件标准差和残差绝对值进行非线性转换,实现了对波动不对称性和长记忆性的同时建模。此外,融合状态转换^[15]、模糊逻辑^[16]等技术的扩展模型,进一步增强了GARCH框架对非正态分布、结构突变等复杂场景的适配能力。

Black-Scholes模型的常数波动率假设无法解释实值/虚值期权隐含波动率高于平值期权的现象,推动了SV模型(Stochastic Volatility Model,随机波动率模型)的发展。Taylor^[17]提出的SV模型将波动率视为不可观测的随机过程,通过随机微分方程描述其动态,能够更好地拟合期权价格的横截面差异,但受限于似然函数难以解析求解,早期应用较为有限。随着MCMC(马尔科夫链蒙特卡洛)技术的成熟^[18],

SV模型的参数估计效率显著提升,成为期权定价的重要补充。与此同时,ARCH/GARCH模型通过刻画波动率的时间序列特征为期权定价提供动态输入,如Engle等^[19]提出的Spline-GARCH模型结合样条函数分离波动率的长期趋势和短期波动,在期权组合的风险中性定价中展现出更高精度;隐含波动率曲面的建模进一步融合期权市场实时数据,形成“模型驱动”与“数据驱动”结合的定价框架,提升了复杂期权的定价准确性^[20]。

机器学习技术的兴起为波动率预测带来了方法论革新。在参数估计环节,遗传算法、粒子群优化等进化算法通过全局搜索优化非凸目标函数,显著降低了厚尾分布数据下的参数估计误差;贝叶斯框架下的MCMC技术则为SV模型提供了更灵活的推断工具,有效解决了不可观测波动率的状态估计问题。模型结构方面,机器学习与GARCH的融合催生了多种混合模型:LSTM-GARCH利用长短期记忆网络捕捉波动率的长期依赖关系,在具有结构突变的金融时间序列中,对波动率转折点的预测准确率较传统模型显著提升^[21];时序卷积网络与GARCH结合,则是通过因果卷积提取高频数据的局部特征,提升了日内波动预测的分辨率。随机森林、XGBoost(Extreme Gradient Boosting,极端梯度提升)等集成算法则通过筛选高频交易数据中的关键特征(如已实现极差、跳跃成分)作为外生输入,增强了GARCH模型对极端波动场景的捕捉能力^[22]。在多源数据处理中,机器学习可进一步整合非结构化数据(如新闻文本、交易订单流)。例如,通过自然语言处理提取市场情绪指标优化波动率预测,或利用深度神经网络直接建模隐含波动率曲面,解决了传统模型对“波动率微笑”拟合时的参数冗余问题^[23]。然而,当前研究仍面临深度学习模型可解释性不足、市场动态适应性有限等挑战,需通过SHAP(SHapley Additive exPlanations,沙普利可加性解释)值分析、注意力机制可视化等技术增强透明度,并探索强化学习与GARCH模型的实时参数调整机制。

国内核心期刊近年来的相关研究中,对GARCH模型族的应用多集中于基础模型或少数扩展形式的对比,对于不同模型在极端行情下的表现差异探讨不足^[24]。同时,在机器学习与波动率预测的结合

研究中,特征选择往往局限于传统的价格滞后项和简单波动率指标,对量价关系、市场状态等深层次特征的挖掘较为欠缺^[25]。本研究在梳理既有成果的基础上,进一步拓展了特征工程的维度,所构建的多时间尺度滞后特征、量价协同指标及市场状态标记等,弥补了国内研究在特征体系完整性上的不足。此外,国内研究对于GARCH模型和机器学习方法在期权定价中的互补性关注较少。在前人的基础上,本研究通过机器学习对比与优化GARCH模型对波动率的预测,以期改善对我国沪深300股指期权的预测,为国内期权定价研究中模型选择的理论依据提供了新的补充,也为实践中结合不同市场环境灵活选用定价模型提供了更具体的指导。

二、GARCH模型建模

(一)研究数据的选取与转换

本文选取沪深300股指期货作为实证研究样本。标的资产方面,选取从2015年4月14日至2025年4月10日共2400个交易日的沪深300指数作为样本,其中2015年4月14日至2024年4月26日样本为训练数据集,2024年4月29至2025年4月10日为测试数据集。期权方面选取2024年7月23日至2024年8月16日的数据为期权定价的测试数据集。同时,选取上海银行间同业拆放利率(Shibor)作为无风险利率。股指收益和无风险利率数据来源包括:Wind数据库、期权数据来源和CSMAR数据库。

计算沪深300股指的收益率时,使用之前研究普遍使用的百分比化的对数收益率^[26],即 $\ln S_t - \ln S_{t-1} = \ln(\frac{S_t}{S_{t-1}})$ 。2015年4月14日至5月13日的沪深300股指收益率如表1所示。

(二)利用GARCH模型对沪深300收益序列进行数据分析

1.描述性统计分析

利用R软件对沪深300股指对数收益率序列进行描述性统计,结果如表2所示。表2中峰度值6.7942大于3,偏度为负,显示收益率分布左偏且尾部更厚,Shapiro-Wilk检验p值小于 $2.2e-16$,不符合正态分布。从图1的收益率时序可以发现,沪深300指数收益率波动率聚集现象明显。

表1 2015年4月14日至5月13日沪深300股指收益率

日期	日收盘价	百分比对数收益率
2015/04/14	4438.18	0.386 263
2015/04/15	4380.51	-1.307 92
2015/04/16	4513.55	2.991 883
2015/04/17	4596.14	1.813 284
2015/04/20	4521.92	-1.628 01
2015/04/21	4619.16	2.127 619
2015/04/22	4739.81	2.578 418
2015/04/23	4740.89	0.022 783
2015/04/24	4702.64	-0.810 08
2015/04/27	4807.59	2.207 187
2015/04/28	4741.86	-1.376 65
2015/04/29	4774.33	0.682 419
2015/04/30	4749.89	-0.513 22
2015/05/4	4787.74	0.793 702
2015/05/5	4596.84	-4.068 94
2015/05/6	4553.33	-0.951 03
2015/05/7	4470.09	-1.845 03
2015/05/8	4558.40	1.956 314
2015/05/11	4690.53	2.857 39
2015/05/12	4747.42	1.205 573
2015/05/13	4718.44	-0.612 31

表2 沪深300股指对数收益率描述性统计

统计量	数值	统计量	数值
均值	-0.0069	标准差	1.3898
中位数	0.0126	偏度	-0.7372
最小值	-9.1544	最大值	8.1420
峰度	6.7942	Jarque-Bera	显著拒绝正态分布

2.平稳性检验

采用ADF(Augmented Dickey-Fuller)检验评估序列平稳性,结果如表3所示。表3中的Dickey-Fuller统计量=-14.188,p值=0.01,滞后阶数=13,在1%的显著性水平上拒绝“存在单位根”假设,对数收益率序列平稳,满足GARCH模型建模前提。

3.自相关性检验

计算滞后10阶沪深300股指对数收益率的自相关系数(ACF)和偏自相关系数(PACF),结果如表4所示。表4的滞后1—10阶ACF值逐渐衰减但非快速趋近0,PACF值在滞后1阶显著(0.035),显示短期自相关性。对滞后10阶和20阶进行Ljung-Box检验,结果如表5所示。表5中滞后10阶时,Q=38.165,p= $3.553 \times 10^{-5} < 0.05$ 。滞后20阶时,Q=88.543,p= $1.331 \times 10^{-10} < 0.05$,说明存在自相关性。后续的分析均默认存在自相关性。




图1 沪深300股指对数收益率时序图

表3 ADF平稳性检验结果

检验统计量	Dickey-Fuller值	p值	滞后阶数	结论
单位根检验	-14.188	0.01	13	平稳(拒绝原假设)

表4 沪深300股指对数收益率ACF与PACF分析表

滞后阶数 k	ACF值 (自相关系数)	PACF值 (偏自相关系数)
0	1.0000	-
1	0.0352	0.0352
2	-0.0259	-0.0272
3	-0.0039	-0.0020
4	0.0246	0.0241
5	-0.0041	-0.0060
6	-0.0858	-0.0844
7	-0.0018	0.0042
8	0.0470	0.0425
9	0.0263	0.0229
10	-0.0534	-0.0498

表5 Ljung-Box自相关性检验结果

滞后阶数	Q统计量	p值	结论
10阶	38.165	3.553×10^{-5}	存在自相关性($p < 0.05$)
20阶	88.543	1.331×10^{-10}	存在自相关性($p < 0.05$)

4.ARCH效应检验

从图1可以发现,沪深300股指收益率具有明显的波动率聚集现象,可以合理推断其残差序列存在异方差性(ARCH效应)。利用拉格朗日乘法法

(LM)进行ARCH效应检验,结果如表6所示。从表6可知,在1%的显著性水平上拒绝“残差序列不存在异方差性”的原假设,因此适合用GARCH模型建模。

表6 沪深300股指对数收益率ARCH效应检验

阶数	卡方	P值
1	176.73	$< 2.2e-16$
2	271.36	$< 2.2e-16$
3	322.19	$< 2.2e-16$
4	344.64	$< 2.2e-16$
5	348.36	$< 2.2e-16$
6	349.14	$< 2.2e-16$
7	350.39	$< 2.2e-16$
8	353.26	$< 2.2e-16$

5.GARCH模型拟合

GARCH模型族常用的模型有GARCH(1,1)、GARCH(2,1)、GARCH(1,2)和GARCH(2,2)等,并且模型的残差分布可以选择为正态分布、t分布等,具有很强的自由性。然而,既有研究成果表明,相较于结构简单的GARCH(1,1)模型,其他更为复杂的模型并未展现出显著的比较优势^[27]。基于此,本

文选择 GARCH (1,1) 模型开展建模分析。从对数收益率序列的描述性统计看,序列的残差很可能不服从正态分布,所以首先拟合 GARCH(1,1)在正态分布假设下的模型,使用卡方拟合优度检验(Chi-square goodness-of-fit test)对残差序列进行是否服从正态分布的检验,结果如表 7 所示。可以发现,表 7 中所有分组都在 1%显著性水平上拒绝“残差序列服从正态分布”的原假设,所以,我们认为,残差序列不服从正态分布。

表 7 残差序列正态分布拟合优度检验

分组	statistic	p-value
20	60.27	3.504e-06
30	78.61	1.848e-06
40	87.02	1.601e-05
50	112.27	7.146e-07

之后的分析中,我们假设残差服从 t-分布进行建模,拟合 t 分布 GARCH(1,1)模型,其参数估计见表 8。从表 8 可以看到,除均值项外,其余参数的显著性检验都通过。表明 t-分布 GARCH(1,1)模型有良好的效果。

模型的具体形式如下:

$$\sigma_t^2=0.0172+0.0686\varepsilon_{t-1}^2+0.9228\sigma_{t-1}^2 \tag{1}$$

表 8 GARCH(1,1)-t 的参数估计

参数	估计值	标准误差	t 值	p-值
μ	0.029 979	0.020 200	1.4841	0.137 778
ω	0.017 240	0.005 947	2.8990	0.003 743
α_1	0.068 626	0.011 105	6.1798	0.000 000
β_1	0.922 794	0.011 260	81.9510	0.000 000

下面,利用 Weighted Ljung-Box 检验验证模型是否消除了自相关性,再利用 LM 检验模型是否消除 ARCH 效应,结果如表 9 和表 10 所示。从表 9 和表 10 可以得出,GARCH 模型可以良好地消除自相关性和 ARCH 效应,具有良好的建模效果。

表 9 Weighted Ljung-Box 检验

滞后期	统计量	p-值
1	2.350	0.1253
2	2.352	0.2105
5	4.650	0.1834

表 10 ARCH-LM 检验结果

滞后期	统计量	Shape 参数	Scale 参数	p-值
3	4.057	0.500	2.000	0.0440
5	4.130	1.440	1.667	0.1625
7	4.190	2.315	1.543	0.3200

事实上,基础的 GARCH 模型具有一些缺陷,但因其形式的对称性,无法把握误差不对称的增减。在实际的金融序列中,负的收益率常常意味着更大的波动率,即波动率存在“杠杆效应”。而 1990 年 Nelson 提出的指数 GARCH 模型(EGARCH)可以捕捉波动率的“杠杆效应”。GJR-GARCH 模型则是另一个能够反映杠杆效应的波动率模型。下面,运用 Python 软件运行 GARCH(1,1)、EGARCH(1,1)和 GJR-GARCH(1,1)模型,并通过 DM 检验(Diebold-Mariano 检验,用于检验产生预测的两个损失序列的平均值是否相等,以比较两个模型之间的预测精度)比较后两种更复杂的模型是否能提供更好的收益率预测,检验结果见表 11。从表 11 中可以发现,所有检验的 p 值都大于 0.05,说明不同模型的预测效果之间没有显著差异。后文均将使用最简单的 t-分布 GARCH(1,1)模型进行相关分析。

表 11 模型 GARCH、EGARCH 和 GJR-GARCH 的 DM 检验

对比模型	DM	p 值
GARCH 与 EGARCH	-0.287 602	0.773 91
GARCH 与 GJR-GARCH	0.378 2607	0.705 58
EGARCH 与 GJR-GARCH	0.632 464	0.527 71

6.使用 GARCH (1,1)-t 预测波动率

基于最优模型 GARCH (1,1)-t 进行向前一步滚动预测。取 2200 个样本(2015—2024 年)用于模型训练,后 230 个样本(2024—2025 年)作为测试集。条件方差方程为:

$$\sigma_t^2=0.0172+0.0686\varepsilon_{t-1}^2+0.9228\sigma_{t-1}^2 \tag{2}$$

由该方程可以计算得到测试样本的预测波动率。再由 $\sqrt{\frac{1}{n} \sum_{i=t-n+1}^t (r_i-\bar{r})^2}$ 计算实际波动率,这里 n 取 11,预测波动率与实际波动率(日)的对比如图 2 所示。2024 年 4 月 29 日至 6 月 3 日的预测结果如表 12 所示,模型的一系列评价指标的计算结果如表 13 所示。表 13 中 MSE(均方误差)较小,表明整体离散程度可控;MAE(平均绝对误差)为 0.2670,属可接受范围;MAPE(平均绝对百分比误差)为 0.3007;R²(决定系数)为 0.7653 的波动率变异,趋势拟合良好。




图2 预测波动率与实际波动率(日)对比

表 12 2024 年 4 月 29 日至 6 月 3 日预测波动率与

实际波动率(日)		
日期	预测波动率	实际波动率(日)
2024/4/29	0.989 9	1.012 163
2024/4/30	1.002 176	0.883 047
2024/5/6	0.981 832	0.867 779
2024/5/7	1.027 473	0.788 784
2024/5/8	0.995 738	0.842 468
2024/5/9	0.987 343	0.812 716
2024/5/10	0.988 66	0.794 651
2024/5/13	0.958 891	0.736 485
2024/5/14	0.930 582	0.756 783
2024/5/15	0.905 161	0.831 587
2024/5/16	0.907 065	0.731 777
2024/5/17	0.887 102	0.723 443
2024/5/20	0.903 161	0.692 617
2024/5/21	0.882 238	0.584 477
2024/5/22	0.863 887	0.586 708
2024/5/23	0.842	0.643 372
2024/5/24	0.874 42	0.649 529
2024/5/27	0.898 642	0.722 605
2024/5/28	0.907 46	0.746 539
2024/5/29	0.902 061	0.749 727
2024/5/30	0.876 96	0.726 318
2024/5/31	0.863 806	0.715 061
2024/6/3	0.846 482	0.627 786

表 13 沪深 300 指数预测核心指标数值

指标	数值
MSE	0.1322
MAE	0.2670
MAPE	0.3007
R ²	0.7653

三、基于机器学习的波动率预测

(一)数据处理与模型构建

1.数据描述性统计

本研究所用数据为沪深 300 指数的行情统计数据。数据经过初步处理,包括去除无关列、重命名字段以及将日期字段转换为标准日期格式,并对包含千分位逗号的数值型字段进行了格式清洗和类型转换,确保后续分析的准确性和统一性。数据包含开盘价(open_price)、最高价(high_price)、最低价(low_price)、收盘价(close_price)等价格指标,涨跌幅(change)、涨跌幅(change_pct)、累计涨跌(cumu_change)、累计涨跌幅(cumu_change_pct)等变动指标,以及成交量(volume_10kshares)和成交额(turnover_10kyuan)指标,如表 14 所示。

2.数据特征工程

本研究的数据特征工程在国内现有研究基础上实现了多维度创新,突破了传统金融时间序列分析中“重价格指标、轻量价协同”“重单一尺度、轻多时间维度”的局限。相较于国内研究在特征选择上多局限于收益率滞后项和基础波动率指标,本研究构建了涵盖价格动态、流动性、市场情绪等指标的多维

度特征体系,不仅包含1—20日多时间尺度的滞后波动率以捕捉短期记忆和长期趋势,还创新性融合了量价协同指标如价格与成交量5/20日相关系数、市场状态标记如基于均线的is_uptrend和波动率扩

张信号is_vol_expanding、极端波动刻画如真实波幅ATR5和日内波动幅度range_ratio5等,覆盖了更丰富的市场信息,更贴合我国A股市场“政策市”与“资金市”交织的复杂特征。

表14 选用指标

变量	count	mean	std	min	max
开盘价(open_price)	2432	3924.928	588.515	2855.60	5922.07
最高价(high_price)	2432	3955.314	592.614	2939.87	5930.91
最低价(low_price)	2432	3894.597	580.633	2821.21	5747.66
收盘价(close_price)	2432	3927.119	587.372	2853.76	5807.72
涨跌值(change)	2432	-0.244	55.204	-370.32	314.17
涨跌幅(change_pct)	2432	0.37%	1.383	-8.75%	8.48%
累计涨跌(cumu_change)	2432	-417.297	587.372	-1490.66	1463.30
累计涨跌幅(cumu_change_pct)	2432	-9.605%	13.520	-34.31%	33.68%
成交量(volume_10kshares)	2432	1 424 729	762 930	441 026.41	6 864 391
成交额(turnover_10kyuan)	2432	22 427 450	12 943 150	4 713 079.56	113 038 700

针对沪深300指数“短期波动剧烈、中长期存在趋势惯性”的特征,本研究在特征工程中实现了时间尺度的分层设计,突破了国内研究常用的“单一时间窗口”局限。其中,短期特征如1/2/3日滞后波动率、momentum5、atr5用于捕捉日内与隔日波动;中期特征如5/10日滞后项、volatility20、ma20反映周度和月度趋势;长期特征如20日滞后波动率、cumu_change_pct刻画季度级别的累积效应,使模型能同时适配我国A股市场的“高频震荡”与“结构突变”场景。

除此之外,还计算了价格与成交量的相关系

数,量价背离等信息,以捕捉价格与交易活跃度之间的关系。价格通道特征通过短期区间振幅和真实波幅等指标,体现价格波动区间及其变化。市场状态标记则基于均线趋势和波动率扩张情况,对市场趋势和波动环境进行了二元分类,方便后续模型对市场情绪和结构的识别。最后,剔除了原始的价格和当日成交数据,统一保留经过计算的衍生特征,并删除缺失值,保证数据的完整性和建模的有效性。

表15是数据特征的详细说明,按照金融时间序列分析进行了规范整理。

表15 数据特征详细说明

量名	定义	经济含义
date	日期	观测时点
cumu_change	累计价格变动	长期绝对收益
cumu_change_pct	累计涨跌幅	长期相对收益
{price}_lag{1-20}	滞后1-20期价格	历史价格记忆效应
return	$\Delta \text{close_price_lag1} / \text{close_price_lag2}$	日收益率
ma{5,10,20}	收盘价{5,10,20}日均值	短期/中期趋势基准
vol_ma{5,10,20}	成交量{5,10,20}日均值	流动性平滑信号
boll_upper/lower	$\text{ma20} \pm 2 \times \text{rolling_std}$	价格波动区间边界
momentum{5,20}	$\text{close_price_lag1} / \text{close_price_lagX} - 1$	中短期价格动能
volatility{5,20}	return的{5,20}日标准差	历史波动率
price_vol_corr{5,20}	价格与成交量{5,20}日相关系数	量价协同效应
range_ratio5	$(\text{high} - \text{low}) / \text{close_price_lag1}$	日内波动相对幅度
atr5	5日最高价-最低价极差	短期真实波动幅度
is_uptrend	$I(\text{close_price_lag1} > \text{ma20})$	多头趋势信号
is_vol_expanding	$I(\text{volatility5} > \text{volatility20})$	波动率扩张信号

3. 建模思路与方法

(1)XGBoost。XGBoost模型的构建注重平衡拟合能力与防止过拟合的需求。具体而言,我们设置了较高的决策树数量以增强模型的表达能力,同时限制树的最大深度为3,以避免模型过于复杂而导致对训练数据的过拟合。较低的学习率被用来细化模型的学习过程,使梯度更新且更加平稳和稳健。此外,通过对样本的子采样和特征子采样设置(分别为0.8),进一步提升模型的泛化效果,减少单一特征或样本对模型训练的影响。为强化模型的正则化能力,特别加入了较强的L1正则化(reg_alpha)和L2正则化(reg_lambda),并调整了gamma和min_child_weight参数,以更好地控制树分裂条件,增强对噪声的抑制能力。模型训练过程中,采用均方根误差(RMSE)和平均绝对误差(MAE)进行多指标监控,确保对预测误差的全面掌控。

(2)随机森林。在本次建模过程中,除了采用XGBoost回归模型外,我们还构建并训练了随机森林回归模型,以对比不同算法在波动率预测任务上

的表现。随机森林作为一种集成学习方法,通过构建多棵决策树并对其预测结果进行平均,有效提升了模型的稳定性和抗过拟合能力。具体参数设置方面,我们选用了200棵决策树,设定最大树深为8,限制了叶节点的最小样本数为5。这些设置既保证了模型具有足够的表达能力,又避免了树结构过于复杂而导致的拟合噪声。训练过程中,随机森林利用全部训练数据进行学习,依托其随机采样和特征选择的机制,增强了模型对样本多样性和特征重要性的捕捉能力。在训练完成后,通过验证集进行了性能评估,计算得到了平均绝对误差(MAE)和均方根误差(RMSE)两个指标。

4.特征重要性分析

研究采用XGBoost模型提供的三种特征重要性评估标准(GAIN、WEIGHT、COVER)进行多维度分析,确保结论的稳健性。三种指标的多维度对比见表16。其中,GAIN为特征在模型分裂时的误差减少量(核心指标),WEIGHT为特征被用作分裂节点的次数,COVER为特征分裂时覆盖的样本量。

表 16 指标多维度对比

特征类型	GAIN 排名	WEIGHT 排名	COVER 排名	稳定性结论
actual_volatility_lag1	2	1	7	分裂次数最优
actual_volatility_lag3	1	5	6	误差减少最强
volatility20	3	2	8	各维度表现稳定
volatility5	4	3	2	覆盖样本量突出

图3的Gain指标衡量的是特征在所有树节点上的平均信息增益,代表该特征带来纯度提升的大小。从图3可以看出,“actual_volatility_lag3”和“actual_volatility_lag5”这两个滞后实际波动率特征贡献最大,显著领先于其他特征,说明过去几日的波动率数据对当前波动率的预测至关重要。“volatility20”和“volatility5”作为波动率类指标,也表现出较强的增益贡献,进一步印证了波动性特征的重要性。

图4的Weight指标反映的是特征在所有树中被使用的次数。图4中“Actual_Volatility_lag1”的使用频率明显高于其他特征,显示模型在分裂节点时倾向于优先使用该特征。同时,多数波动率相关变量也频繁被调用,表现为更高的权重值,表明这些特征在模型构建过程中被频繁利用以捕捉波动率的变化

模式。

图5的Cover指标则衡量了特征所覆盖的样本比例,即特征分裂节点覆盖数据的平均权重。从图5可以发现,“Actual_Volatility_lag1”覆盖范围最大,紧随其后的是短期波动率指标(volatility20)、波动率指标(rolling_Std)及短期波动率指标(volatility5)。这表明这些特征不仅在节点分裂中作用显著,同时也影响了大量样本的路径,显示出其对整体模型预测能力的广泛贡献。

综合来看,这三种重要性指标各有侧重,但均表明历史波动率的滞后特征和相关波动率指标在模型中扮演核心角色,动量和成交量类指标也为模型提供了补充信息,增强了波动率预测的准确性和稳定性。这些结果为后续的特征选择和模型优化提供了有效依据。




图3 XGBoost 模型特征重要性指标——GAIN 指标(前 17)

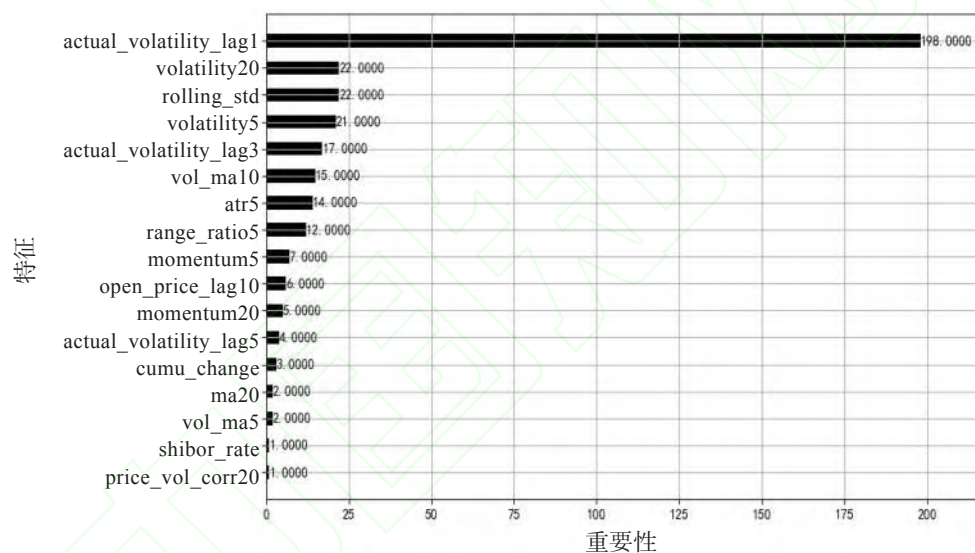


图4 XGBoost 模型特征重要性指标——WEIGHT 指标(前 17)




图5 XGBoost 模型特征重要性指标——COVER 指标(前 17)

5. SHAP 分析

在本项目的模型解释部分,我们引入了SHAP (SHapley Additive exPlanations)方法,对XGBoost回归模型的输出进行了深入分析。通过SHAP分析,我们可以定量解释每个特征在样本层面对模型预测结果的实际影响,从而全面提升模型的可解读性和业务指导性。

从图6可以看出,模型中最具影响力的特征依然是“actual_volatility_lag1”,其SHAP值范围最大且整体对模型输出贡献正向影响明显,表明过去一天的实际波动率对当前波动率预测起到了关键性作用。其次,“Actual_Volatility_lag3”、波动率指标“volatility20”和“volatility5”等特征也表现出显著的正向贡献,这与其较高的特征值(标记为深色)对应较高的预测输出一致,说明较高的历史波动率往往推动模型给出更高的波动率预测值。其他如“atr5”“rolling_std”等波动幅度相关指标也呈正相关,但其

影响较前几者稍弱。浅色点表示较低特征值,往往对应负向贡献或较低的波动率预测。

SHAP分析有效揭示了各特征对波动率预测的影响模式与我国A股市场特征的内在关联。actual_volatility_lag1的SHAP值范围最大且整体呈正向贡献,结合actual_volatility_lag3等滞后波动率特征的显著正向影响,印证了我国A股市场短期波动的强持续性——散户投资者占比较高的市场结构下,前1至3天的高波动率易通过跟风交易形成“波动聚集”,推动当前波动率预测值上升。SHAP分析中volatility5与volatility20的动态影响差异,则反映了我国A股“短期情绪与中期趋势博弈”的特征:5日波动率(代表游资炒作、日内交易等短期资金冲击)在市场震荡期SHAP值升高,而20日波动率(反映政策导向、机构持仓调整等中期因素)在趋势形成期权重上升,体现了“政策市”与“资金市”交织的市场属性。

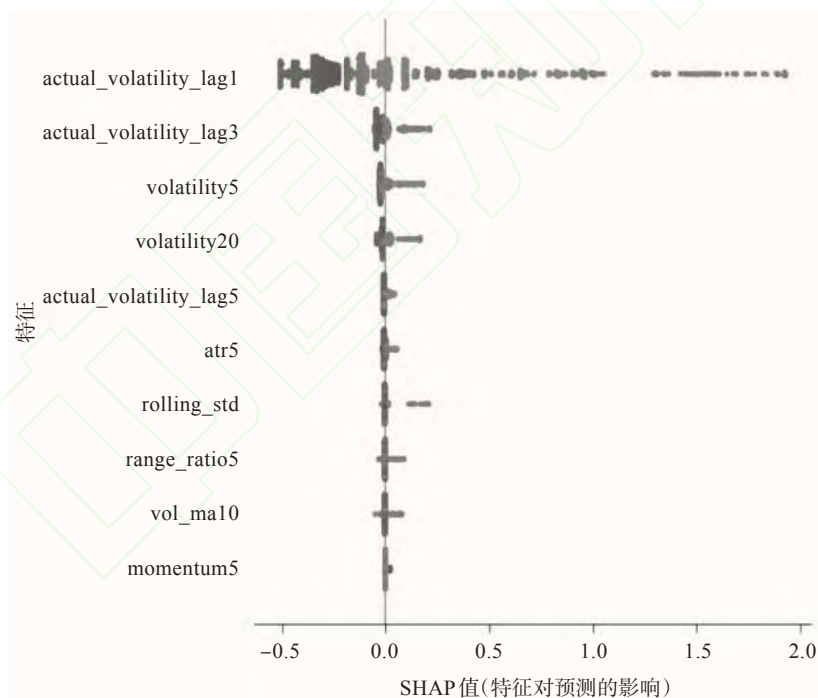


图6 特征影响方向分析(前10)

总体而言,SHAP分析不仅确认了模型将实际波动率的滞后值和波动率相关指标作为主要驱动力,还揭示了各特征对单条样本预测的正负影响,提高了模型的解释性和可信度,为后续模型的优化和风险管理提供了直观依据。

(二)GARCH模型与XGBoost模型、随机森林模型对比

在本项目的建模和评估环节,我们将传统计量

的GARCH模型与XGBoost、随机森林两种机器学习模型进行对比,旨在检验机器学习算法在金融市场波动率预测这一任务上的性能表现。

我们通过计算测试集上的平均绝对误差(MAE)和均方根误差(RMSE)客观度量各模型预测精准度,如图7所示。具体预测对比结果为:GARCH模型的MAE为0.2701、RMSE为0.3669;XGBoost模型的MAE为0.1146、RMSE为0.2271;随机森林模型的MAE为

0.1011、RMSE为0.2140。由此可见,GARCH模型的误差显著高于机器学习模型,XGBoost模型和随机森林模型的MAE均下降至0.1以内、RMSE降至0.23及以下,表明通过滞后特征和多维信息挖掘,机器学习

方法能更有效地捕捉波动率的变化并减少大幅错误,其中随机森林模型表现突出,在所有模型中其MAE和RMSE均最小,验证了其高效的特征利用和泛化能力。




图7 GARCH模型与XGBoost模型、随机森林模型的对比

图7中GARCH模型与XGBoost模型、随机森林模型的对比反映了三类模型在测试集中的预测误差分布和拟合优度,机器学习模型的MAE、RMSE均显著低于GARCH模型,说明其在预测实际波动率时,能显著减少平均误差和大幅离群点的影响;同时,XGBoost模型和随机森林模型的 R^2 均值高于GARCH模型,表明其在整体拟合能力和对复杂数据结构的感知能力上的提升。在真实市场应用中,更低的MAE和RMSE意味着模型能够避免高频误判或高强度风险暴露,对券商、资产管理和量化对冲等场景有直接价值。从两种机器学习模型的横向对比来看,随机森林模型的误差指标略优于XGBoost模型且 R^2 也略高,这可能归因于其对特征多样性和自适应性采样机制的良好兼容性,不过两者整体表现都远超GARCH模型,充分体现了基于历史特征量化建模的效能。

四、机器学习增强GARCH模型

下面,通过构建新的特征工程的方式,将GARCH模型与机器学习进行融合,利用机器学习模型对

GARCH模型的预测结果进行增强。

首先,我们利用GARCH模型计算出每日的当日预测波动率,在特征工程中用其代替真实波动率的滞后项,因GARCH模型预测的当日波动率已经包含时间序列的趋势信息,同时保留其他特征。

利用XGBoost增强模型、随机森林增强模型和GARCH模型的预测结果,计算测试集上的平均绝对误差(MAE)和均方根误差(RMSE),客观度量各模型的预测精准度。从图8可知,其结果为:XGBoost增强模型的MAE为0.3552、RMSE为0.4336;随机森林增强模型的MAE为0.1935、RMSE为0.3582。由此可见,两个增强模型在波动率预测上,误差高于原模型及其学习模型,但随机森林模型仍然可以降低GARCH模型的误差。以表现较好的随机森林模型为例,采用内置特征重要性分析方法进行重要性分析。图9的内置特征重要性分析结果显示,GARCH模型预测的波动率(Forecast Volatility)重要性占比为0.7136,同时月度历史波动率特征(volatility20)贡献了0.1355的重要性。

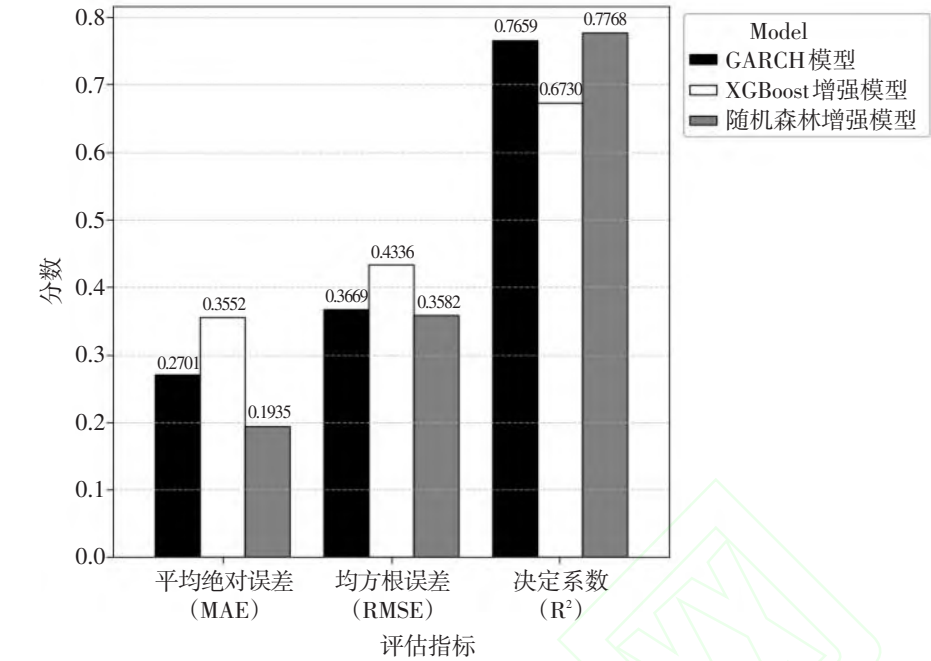


图8 机器学习增强后的模型与原GARCH模型预测对比

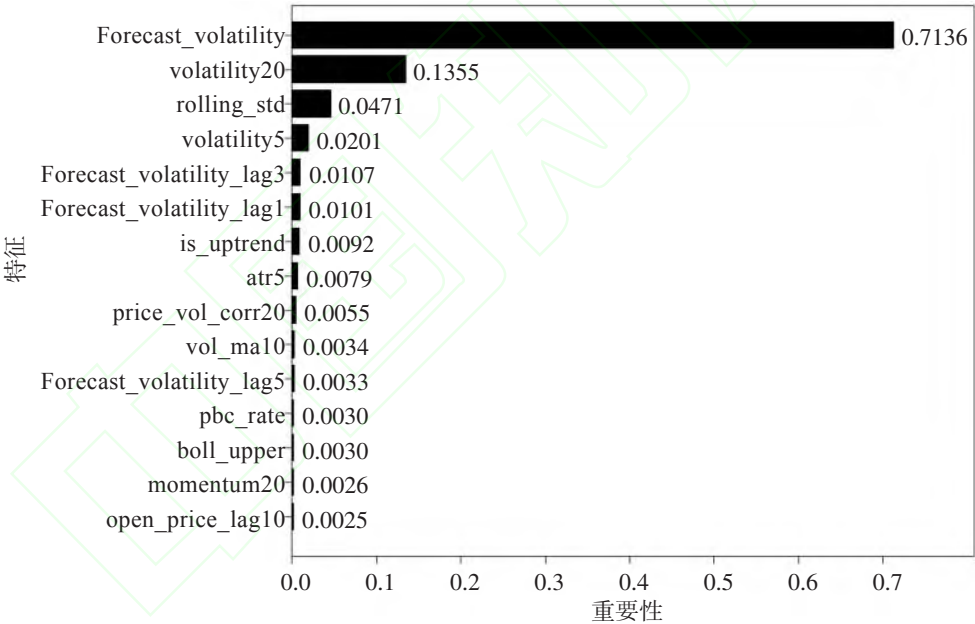


图9 随机森林增强算法内置特征重要性分析(前15)

这样的结论与前文中真实收益率的短期滞后项及月度历史波动率特征占特征重要性的主要部分的结论类似,说明沪深300指数波动率有强烈的时间序列相关性,即短期相关效应显著,且长期也有一定相关。

五、沪深300股指期权定价实证分析

(一)数据选取与预处理

本文选取2024年7月23日至2024年8月16日的沪深300股指期权作为研究样本,利用前文训练的GARCH模型、XGBoost模型和随机森林模型预测

的波动率作为输入参数,通过Black-Scholes期权定价公式求得期权的理论价值。Black-Scholes公式输入的数据选取如下:(1)波动率,用GARCH模型、XGBoost模型、随机森林模型预测的年化波动率;(2)期权当日价格,采用期权当日的收盘价格;(3)期权有效期,以一年252个交易日为基准计算的期权有效期,选取有效期在10到100个交易日之内的期权数据,防止非正常波动的出现;(4)无风险利率,使用上海银行间同业拆借率(Shibor);(5)执行价格,研究范围内的标的资产价格在3320到3500点上下浮

动,故选取执行价格为3300、3400、3500的看涨看跌期权进行研究;(6)股息红利收益率,为简化计算,此处默认为0;(7)标的资产价格,选取当日的资产(沪深300指数)收盘价为标的资产价格。根据以上原则筛选,得到共计342条数据。

(二)模型的预测效果对比

分别利用GARCH模型,XGBoost模型,随机森林模型及其增强模型预测的波动率,通过Black-Scholes公式计算行权价为3300、3400、3500的看涨看跌期权价格,用均方误差(MSE)和平均绝对误差(MAE)来评估模型定价与期权实际价格的偏差,结果如表17所示。

表 17 各模型MSE与MAE检验

模型	认购/认沽	MSE	MAE
GARCH	认购	736.161	23.436
XGBoost	认购	580.638	19.865
随机森林	认购	560.008	19.300
XGBoost增强	认购	2247.730	24.961
随机森林增强	认购	385.760	14.796
GARCH	认沽	153.170	8.728
XGBoost	认沽	222.825	10.701
随机森林	认沽	250.602	11.530
XGBoost增强	认沽	541.735	18.472
随机森林增强	认沽	399.740	15.116

由表17可知,在认购期权定价方面,对执行价格为3300、3400、3500的认购期权定价,XGboost和随机森林模型的定价误差没有显著差异,但是都优于GARCH模型的定价误差。而对于认沽期权,GARCH模型则优于XGBoost模型和随机森林模型。初步分析认为,这可能是XGBoost和随机森林模型对于负面消息的反应过于剧烈造成的。对于增强模型,可以发现,XGBoost增强模型的效果不理想,其在认购、认沽两种期权的定价误差都高于原XGBoost模型和GARCH模型。而随机森林模型虽然在认沽期权定价的误差上仍然高于GARCH模型,但在认购期权的定价误差上明显优于GARCH模型和原随机森林模型,表现出良好的模型融合效果。

六、结论与展望

(一)结论

本研究的理论和实践价值可置于国家深化资本市场改革的战略框架中审视。党的二十届三中全会将资本市场改革作为构建高水平社会主义市场经济

体制的核心环节,在《中共中央关于进一步全面深化改革 推进中国式现代化的决定》中明确提出“健全投资和融资相协调的资本市场功能”,这一部署凸显了资本市场在服务新质生产力、优化资源配置中的枢纽作用。从宏观层面看,当前我国资本市场正处于从规模扩张向质量提升的转型关键期。根据证监会和三大交易所披露,2024年,我国A股战略性新兴产业上市公司数量占比已超50%;科创板、创业板及北交所新增企业中,80%属于硬科技领域,这一结构性变革印证了资本市场对国家创新驱动战略的支撑效能。然而,我国资本市场中长期资金持股比例不足6%,远低于境外成熟市场,市场波动风险和服务实体经济的深度仍有提升空间。

本研究通过融合GARCH模型与机器学习技术优化股指期货定价,系统地探讨了传统的时间序列GARCH模型与新兴的机器学习模型在波动率预测和期权定价上的差异,并且创新性地将二者进行融合。本研究提出的模型融合方案,不仅简单易实现,不需要消耗大量的计算资源,而且在认购期权定价上有良好的表现。理论层面,本研究为解决传统金融模型对极端行情响应滞后的理论难题提供新路径。市场特征层面,SHAP分析揭示的滞后波动率、量价指标等对预测的影响模式,验证了我国A股散户主导下短期波动持续性、政策与资金交织驱动波动等典型特征,为模型在A股市场的适配性提供了实证支撑,使结论更贴合市场实际。实践层面,更契合党的二十届三中全会“建立增强资本市场内在稳定性长效机制”的改革要求,对完善衍生品定价机制、提升风险管理水平、助力资本市场服务科技创新和产业升级具有现实意义。

(二)展望

尽管本研究在波动率建模与期权定价的交叉领域取得了阶段性进展,当前模型框架仍存在进一步拓展和优化的空间。机器学习模型的“黑箱”特性导致其决策逻辑难以被直观解读,这在一定程度上限制了其在监管合规和深度风险控制场景中的应用,未来可结合注意力机制可视化等技术,增强模型决策过程的透明度,同时探索强化机器学习与GARCH模型的动态参数调整机制,提升模型对市场结构变化的实时适应能力。

同时,未来研究可紧密围绕党的二十届三中全

会提出的资本市场改革方向,从政策实践和理论创新双重维度展开。在政策层面,需聚焦“投融资协调发展”这一核心目标,探索扩大科技创新债券发行规模、推动上市公司分红和再融资资格挂钩等机制,以强化“投资—回报”良性循环;同时借鉴国际经验,优化养老金、保险资金等长期资金入市的税收优惠政策,逐步改善市场投资者结构。在理论创新方面,可深入研究注册制改革背景下硬科技企业的估值逻辑,结合党的二十届三中全会“健全投资者保护机制”的要求,探索智能监管系统在防范程序化交易风险中的应用,推动监管科技与金融市场深度融合。从国家战略视角,资本市场改革需进一步对接“一带一路”倡议,探索区域性股权市场与境外交易所的互联互通机制,提升我国资本市场的国际影响力。本研究的模型框架可延伸至绿色股指期货等创新产品定价,为构建“规范、透明、开放、有活力、有韧性”的资本市场提供方法论支撑,切实落实党的二十届三中全会关于“全面提升资本市场服务中国式现代化能力”的改革要求。

在数据维度和模型创新方面,目前研究主要依赖结构化金融数据,对新闻文本、社交媒体情绪、交易订单流等非结构化数据的挖掘尚未充分展开,后续可借助自然语言处理、图神经网络等技术整合多源信息,丰富波动率预测的特征输入,进一步捕捉市场情绪和微观结构对波动的影响。此外,针对期权定价中常见的“波动率微笑”“期限结构”等复杂现象,可探索深度学习模型(如LSTM、Transformer)与传统计量模型的充分融合,提升对非线性波动模式的刻画能力。

从应用场景拓展来看,沪深300股指期货期权市场的研究框架可进一步延伸至商品期权、外汇期权等其他衍生品领域和大宗商品等领域^[28],检验模型的普适性并优化其对不同市场特性的适配能力。值得关注的是,极端风险场景下的模型鲁棒性仍是重要研究方向,未来可引入极值理论(EVT)、贝叶斯模型平均(BMA)等方法,强化对尾部风险的预测能力,为系统性风险管理提供更可靠的工具支撑。随着金融科技的快速发展,波动率建模与期权定价研究需持续融合前沿方法和市场实践,在模型可解释性、多源数据融合、极端场景适应性等方面展开更深层的探索,为我国金融衍生品市场的稳健运行和创新发

展提供更具前瞻性的解决方案。

参考文献:

- [1] Engle R. F. *Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation* [J]. *Econometrica: Journal of the Econometric Society*, 1982, 50(4): 987-1007.
- [2] Bollerslev T. *Generalized Autoregressive Conditional Heteroskedasticity* [J]. *Journal of Econometrics*, 1986, 31(3): 307-327.
- [3] 杨洪. 基于ARMA-GARCH模型的VIX指数波动性思考[J]. *青海金融*, 2025(7): 43-50.
- [4] 殷秀莉. 基于几类GARCH-SVR模型的金融收益序列波动性预测[D]. 长春: 长春工业大学, 2023.
- [5] 许敏, 盛静文, 袁欣. 基于机器学习偏差校正的GARCH波动率模型预测[J]. *计算机应用与软件*, 2023(8): 98-103.
- [6] BLACK F., SCHOLES M. *The Pricing of Options and Corporate Liabilities* [J]. *Journal of Political Economy*, 1973, 81(3): 637-654.
- [7] 吴嘉伟, 孙升雪, 王力卉, 等. 与期权定价模型相关的参数估计的研究综述[J]. *时代金融*, 2015(32): 268-269.
- [8] Andersen T. G., Bollerslev T. *Deutsche Mark-dollar Volatility: Intraday Activity Patterns, Macroeconomic Announcements, and Longer Run Dependencies* [J]. *the Journal of Finance*, 1998, 53(1): 219-265.
- [9] Corsi F. *A Simple Approximate Long-memory Model of Realized Volatility* [J]. *Journal of Financial Econometrics*, 2009, 7(2): 174-196.
- [10] Ghysels E., Sinko A., Valkanov R. *MIDAS Regressions: Further Results and New Directions* [J]. *Econometric Reviews*, 2007, 26(1): 53-90.
- [11] Nelson D. B. *Conditional Heteroskedasticity in Asset Returns: A New Approach* [J]. *Econometrica: Journal of the Econometric Society*, 1991, 59(2): 347-370.
- [12] Glosten L. R., Jagannathan R., Runkle D. E. *On the Relation Between the Expected Value and the Volatility of the Nominal Excess Return on Stocks* [J]. *The Journal of Finance*, 1993, 48(5): 1779-1801.
- [13] Baillie R. T., Bollerslev T., Mikkelsen H. O. *Fractionally Integrated Generalized Autoregressive Conditional Heteroskedasticity* [J]. *Journal of Econometrics*, 1996, 74(1): 3-30.
- [14] Tse Y. K. *The Conditional Heteroscedasticity of the Yen-dollar Exchange Rate* [J]. *Journal of Applied Econometrics*, 1998, 13(1): 49-55.
- [15] Gray S. F. *Modeling the Conditional Distribution of Interest Rates as a Regime-switching Process* [J]. *Journal*

- of Financial Economics, 1996, 42(1): 27–62.
- [16] Maciel L., Ballini R., Gomide F. *Evolving Possibilistic Fuzzy Modeling for Realized Volatility Forecasting with Jumps* [J]. IEEE Transactions on Fuzzy Systems, 2016, 25(2): 302–314.
- [17] Taylor S. J. *Modeling Stochastic Volatility: A Review and Comparative Study* [J]. Mathematical Finance, 1994, 4(2): 183–204.
- [18] 刘酉君. 随机波动模型参数估计方法比较研究[D]. 天津: 天津大学, 2007.
- [19] Engle R. F., Rangel J. G. *The Spline-GARCH Model for Low-frequency Volatility and Its Global Macroeconomic Causes* [J]. The Review of Financial Studies, 2008, 21(3): 1187–1222.
- [20] 许敏. 基于GARCH-GA-BP模型的股市波动率预测研究[J]. 中小企业管理与科技, 2024(14): 124–126.
- [21] Ghysels E., Santa-Clara P., Valkanov R. *Predicting Volatility: Getting the Most Out of Return Data Sampled at Different Frequencies* [J]. Journal of Econometrics, 2006, 131(1–2): 59–95.
- [22] Patton A. J., Sheppard K. *Good Volatility, Bad Volatility: Signed Jumps and the Persistence of Volatility* [J]. Review of Economics and Statistics, 2015, 97(3): 683–697.
- [23] Corsi F., Renò R. *Discrete-time Volatility Forecasting with Persistent Leverage Effect and the Link with Continuous-time Volatility Modeling* [J]. Journal of Business & Economic Statistics, 2012, 30(3): 368–380.
- [24] 许敏. 基于数据驱动的波动率模型研究进展[J]. 上海管理科学, 2024(6): 50–55.
- [25] 张迅. 基于波动率预测的期权市场交易策略的研究[D]. 成都: 电子科技大学, 2025.
- [26] 王玉荣. 中国股票市场波动性研究: ARCH模型族的应用[J]. 河南金融管理干部学院学报, 2002(5): 36–37.
- [27] 童旭辉. GARCH模型经机器学习改进后的期权定价波动率分析[D]. 南京: 南京师范大学, 2020.
- [28] 鲁春义, 陈炳宜. 大宗商品金融化的价值本质和价格特征: 基于波动率视角的实证研究[J]. 征信, 2020(9): 71–79.

(责任编辑: 牛 茜)

Research on Volatility Prediction and Option Pricing Based on GARCH Model and Machine Learning

Jiang Xiaoyang¹, Xie Jiangyu¹, Yan Tingzheng², Gong Qihui¹

(1. School of Management, Zhejiang University, Hangzhou 310058, Zhejiang, China;

2. School of Economics, Zhejiang University, Hangzhou 310058, Zhejiang, China)

Abstract: As the core component of option pricing, volatility modeling is crucial for enhancing pricing power within China's financial markets and improving the risk management framework. Focusing on the volatility modeling challenge for the CSI 300 index option pricing, this study employs the GARCH model family to analyze the volatility clustering and dynamic characteristics of financial time series. We construct a GARCH(1,1)-t model to capture the time-varying volatility of CSI 300 index returns. Furthermore, machine learning algorithms, including Random Forest and XGBoost, are introduced to extract additional predictive features such as multi-dimensional lagged historical volatility values, momentum indicators, and moving averages of trading volume, thereby improving volatility prediction accuracy in complex market environments. Empirical results demonstrate that while the GARCH model effectively captures general volatility trends, it exhibits delayed responses during extreme market conditions. In contrast, machine learning models leverage their nonlinear modeling capabilities to significantly reduce short-term volatility prediction errors. The study further reveals a complementary relationship between the two model types in option pricing: machine learning models excel when the underlying asset exhibits upward volatility, whereas the GARCH model, benefiting from its symmetric assumption and robustness to downside risk, performs better for pricing put options.

Keywords: GARCH Model; machine learning; CSI 300 Stock Index Option; volatility prediction; option pricing